

Szyfr Vigenere

2 października 2014

Ten szyfr jest modyfikacją szyfru Cezara. Kluczem jest n-literowe słowo. Tekst zaszyfrowany otrzymujemy poprzez dodanie do wiadomości klucza. Przykład:

tekst: bardzosièceszewreszczaczalsierokakademicki

klucz: kłamstwo

wiadomość zaszyfrowana: llrprhowoniqksanohrqksywokaorthgspractgonpmuude

pierwszy blok: $b+k = (1+10)\%26 = 11 = l$, $a+l = (0 + 11)\%26 = 11 = l$, $r+a = (17+0)\%26=17=r$, $d+m = (3+12)\%26 = 15 = p$, $z+s = (25+18)\%26 = 17=r$, $o+t = (14+19)\%26 = 7 = h$, $s+w = (18+22)\%26=14=o$, $i+o = (8+14)\%26=22=w$ deszyfrowanie $l-k = (11-10)\%26 = (11-10+26)\%26 = (11+16)\%26=1=b$ itp.

Część 1 zadania: napisać program szyfrujący, tekst do szyfrowania ma pochodzić z pliku, klucz ustawić można w programie.

Kryptoanaliza szyfru Vignere'a

Pierwszym krokiem do wydobywania z zaszyfrowanego tekstu klucza jest ustalenie jego długości. W tym celu wykorzystać można indeks zgodności $I_c(x)$, który określa prawdopodobieństwo tego, że dwa wyrazy w ciągu x są identyczne. Przyjmijmy, że częstość wystąpienia w ciągu x o długości n liter a, b, \dots, z wynosi odpowiednio f_0, f_1, \dots, f_{25} , wtedy

$$I_c(x) = \frac{\sum_{i=0}^{25} f_i * (f_i - 1)}{n * (n - 1)} \quad (1)$$

dla języka angielskiego $I_c(x^{ang}) \approx 0,065$. Domyślamy się, że klucz ma długość d , dzielimy więc tekst na bloki $x_0 x_d x_{2d} \dots$, $x_1 x_{d+1} x_{2d+1} \dots$ i dla każdego z bloków obliczamy I_c (dla całkowicie losowego ciągu $I_c \approx 0,038$). Jeżeli dla każdego z bloków I_c ma wartość zbliżoną do 0,065 to mamy podstawy sądzić, że klucz ma długość d . Jeżeli nie, należy wykonać obliczenie dla innej długości d' tak długo aż uzyskamy zadowalającą zgodność.

Przykład

klucz: can

tekst: itwasagoodwar...

wiadomość zaszyfrowana: ktjcsniobfwnt...

Zakładana długość klucza 2, mamy dwa bloki:

1: k,j,s,i,b,w,t ...

2: t,c,n,o,f,n ...

Dla każdej z grup obliczamy I_c : 1 - $I_c \approx 0.042$, 2 - $I_c \approx 0.048$. Wartości wskazują na to, że ten podział nie jest prawidłowy. Następnym krokiem jest zmiana długości klucza na 3. Wtedy mamy 3 grupy (w nawiasach podane wartości I_c dla tego podziału):

1: k,c,i,f,t ... ($I_c \approx 0.061$)

2: t,s,o,w, ... ($I_c \approx 0.069$)

3: j,n,b,n, ... ($I_c \approx 0.069$)

Wartości wskazują na to, że jest to prawidłowa długość klucza (można sprawdzić, że dla długości 4 wartość I_c dla każdej grupy spadnie).

Zakładając, że ustaliliśmy długość klucza i wynosi ona d możemy przystąpić do wyznaczenia klucza. W tym celu ponownie korzystamy z bloków postaci $x_0 x_d x_{2d} \dots$, $x_1 x_{d+1} x_{2d+1} \dots$. Załóżmy, że częstość występowania liter a, b, \dots, z w tych ciągach wynosi odpowiednio f_0, f_1, \dots, f_{25} oraz $f'_0, f'_1, \dots, f'_{25}$. Wzajemny indeks zgodności definiujemy jako

$$MI_c(x, x') = \frac{\sum_{i=0}^{25} f_i * f'_i}{n * n'} \quad (2)$$

gdzie n, n' to długości odpowiednich ciągów. Wiemy, że klucz składa się w d liter $k = (k_1, k_2, \dots, k_d)$. Wzajemny indeks zgodności pozwala określić relację pomiędzy poszczególnymi k_i . Przyjmijmy, że rozważamy elementy zaszyfrowane przez k_1 i k_2 . Jeżeli

obliczając MI_c uzyskamy wartość $MI_c(x, x') \approx 0,065$ oznacza to, że $k_1 = k_2$, jeżeli nie to przesuwamy wyrazy w ciągu x' (a występowało f'_0 razy, po przesunięciu tyle razy występować będzie b a a będzie występować teraz f'_{25} razy) i znowu obliczamy MI_c (formalnie $MI_c(x, x') = \frac{\sum_{i=0}^{25} f_i(f'_{i-g})}{n*(n')}$). Ostatecznie, po znalezieniu odpowiedniej wartości g będziemy wiedzieli, że $k_1 - k_2 = g$. Ponieważ postępowanie to opiera się na statystyce tekstu w języku angielskim należy je stosować dla: 1) długich tekstów 2) kluczy krótkich w stosunku do długości tekstu. Niech $d=5$, wtedy $k = (k_1, k_2, k_3, k_4, k_5)$. Praktycznie jest wyznaczyć indeksy zgodności dla wszystkich par $(k_1, k_2), \dots, (k_1, k_5), (k_2, k_3), \dots, (k_2, k_5)$ bo w zależności od specyficznego tekstu nie musi być tak, że tylko pary $(k_1, k_2), \dots, (k_1, k_5)$ dadzą nam rozwiązanie. Ostatecznie uwzględniając relacje pomiędzy znakami klucza powinniśmy móc napisać, że klucz jest postaci $k = (k_1, k_1 + y_2, k_1 + y_3, k_1 + y_4, k_1 + y_5)$. Następnym krokiem może być podstawienie za k_1 wszystkich możliwych liter i sprawdzenie, użycie którego klucza daje sensowną wiadomość

Przykład

Kontynuując poprzedni przykład (tekst angielski, podział na 3 grupy) mamy następujące częstości występowania liter a...z w grupie 1 oraz 2:

1: $[f_0^1, \dots, f_{25}^1] = [5, 0, 33, 7, 9, 13, 30, 4, 5, 23, 19, 1, 2, 14, 9, 21, 18, 7, 1, 13, 17, 26, 5, 1, 9, 2]$

2: $[f_0^2, \dots, f_{25}^2] = [27, 1, 4, 15, 39, 5, 5, 22, 21, 0, 1, 9, 7, 15, 20, 8, 0, 16, 26, 29, 6, 2, 9, 1, 5, 0]$

Na początku liczymy $\frac{1}{n^1 * n^2} (f_0^1 * f_0^2 + \dots)$ co daje $MI_c \approx 0.029$, następnie $\frac{1}{n^1 * n^2} (f_0^1 * f_{25}^2 + f_1^1 * f_0^2 \dots) \approx 0.039$ aż dochodzimy do $\frac{1}{n^1 * n^2} (f_0^1 * f_{24}^2 + f_1^1 * f_{25}^2 \dots) \approx 0.066$.

Część 2 zadania: napisać program, który wyznacza długość klucza (tekst w języku angielskim) i podaje względne relacje pomiędzy wyrazami klucza (nie trzeba zapisywać klucza w postaci, $k = (k_1, k_1 + y_2, k_1 + y_3, k_1 + y_4, k_1 + y_5)$ wystarczy wypisać pozytywne wyniki analizy wzajemnego indeksu zgodności na ekran np. w postaci k_1, k_2, g itp.)

Punktacja (łącznie 10 punktów):

- 3 punkty - parawidłowo działająca pierwsza część zadania, czyli wczytanie tekstu z pliku i zaszyfrowanie go oraz wpisanie zaszyfrowanego tekstu do pliku. Nazwy plików można ustalić w programie, nie muszą być podawane przez użytkownika.
- 3 punkty - wczytanie zaszyfrowanego tekstu z pliku i obliczenie indeksu zgodności dla zadanego przez użytkownika podziału na grupy, ewentualnie obliczanie indeksu zgodności w pętli dla podanego przez użytkownika górnego zakresu sprawdzania (maksymalnie 10 grup).
- 4 punkty - dla zadanej przez użytkownika ilości grup obliczenie wzajemnego indeksu zgodności między wszystkimi grupami.